## Reference genomes and Common file formats The Rockefeller University

**Bioinformatics Resource Centre** 

## Overview

- Reference genomes and GRC.
- Fasta and FastQ (Unaligned sequences).
- SAM/BAM (Aligned sequences).
- BED (Genomic Intervals).
- GFF/GTF (Gene annotation).
- Wiggle files, BEDgraphs and BigWigs (Genomic scores).

## Are there we there yet?

- The human genome isnt complete!
- In fact, most model organisms's reference genomes are being regularly updated.
- Reference genomes consist of mixture of known chromosomes and unplaced contigs called a " Genome Reference Assembly".
- Major revisions to assembles result in change of co-ordinates.
  - Requires conversion between revisions.
  - The latest genome assembly for humans is GRCh38.
- Patches add information to the assembly without disrupting the chromosome coordinates.i.e GRCh38.p3

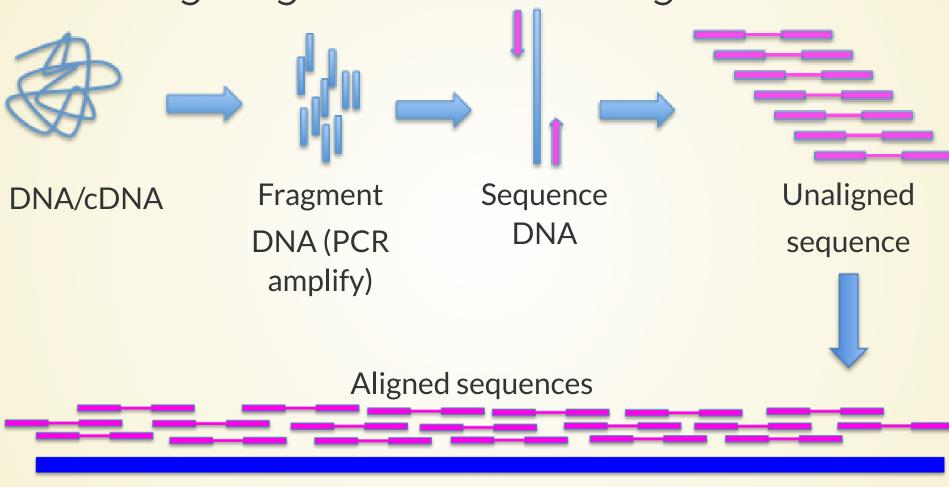
## Genome Reference Consortium

- GRC is collaboration of institutes which curate and maintain the reference genomes for 3 model organims.
  - Human GRCh38.p3
  - Mouse GRCm38.p3
  - Zebrafish GRCz10
- Other model organisms are maintained separately.
  - Drosophila Berkeley Drosophila Genome Project, BDGP36

# Why do we need to know about reference genomes

- Allows for genes and genomic features to be evaluated in their linear genomic context.
  - Gene A is close to Gene B
  - Gene A and Gene B are within feature C.
- Can be used to align shallow targeted highthoughput sequencing to a pre-built map of an organisms genome.

## Aligning to a reference genomes



Reference genome

## A reference genome

- A reference genome is a collection of contigs.
- A contig is a stretch of DNA sequence encoded as A,G,C,T,N.
- Typically comes in FASTA format.
  - ">" line contains information on contig
  - Lines following contain contig sequence
    - >gi|568336023|gb|CM000663.2| Homo sapiens chromosome 1, GRCh38 reference primary assembly CCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTA ACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCC TAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCC CCTAACCCTAACCCTAACCCTAACCCCTAACCCCTAACCCTAACCCTAACCCTAACCCTAACCC TCTGACCTGAGGAGAACTGTGCTCCGCCTTCAGAGTACCACCGAAATCTGTGCAGAGGACAACGCAGCTC CGCCCTCGCGGTGCTCTCCGGGTCTGTGCTGAGGAGAACGCAACTCCGCCGTTGCAAAGGCGCGCCGCGC 11 12 13 CGCGCCGGCGCAGGCGCAGACACATGCTAGCGCGTCGGGGTGGAGGCGTGGCGCAGGCGCAGAGAGGG GCCGCGCCGCGCAGGCGCAGAGACACATGCTACCGCGTCCAGGGGTGGAGGCGTGGCGCAGGCGCA 15 AGGCGCACCGCGCGCGCAGGCGCAGAGACACATGCTAGCGCGTCCAGGGGTGGAGGCGTGGCGCAGGC GCAGAGACGCAAGCCTACGGGCGGGGTTGGGGGGGCGTGTTTTGCAGGAGCAAAGTCGCACGGCGCCGG 17 18 19 GCTTGCTCACGGTGCTGTGCCAGGGCGCCCCCTGCTGGCGACTAGGGCAACTGCAGGGCTCTCTTGCTTA 20 GAGTGGTGGCCAGCGCCCCTGCTGGCGCCGGGGCACTGCAGGGCCCTCTTGCTTACTGTATAGTGGTGG

## High-throughput Sequencing formats

Unaligned sequence files generated from HTS machines are mapped to a reference genome to produce aligned sequence files.

- FASTQ Unaligned sequences
- SAM Aligned sequences

## Unaligned Sequences

#### FastQ (FASTA with Qualities)

```
@HS2000-887_89:5:1101:1595:156011/1

ACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAA
```

- "@" followed by identifier.
- Sequence information.
- "+"
- Quality scores encodes as ASCI.

## Unaligned Sequences

#### FastQ - Header

```
@HS2000-887_89:5:1101:1595:156011/1

2    ACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCTAACCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACC
```

- Header for each read can contain additional information
  - HS2000-887\_89 Machine name.
  - 5 Flowcell lane.
  - /1 Read 1 or 2 of pair (here read 1)

## Unaligned Sequences

#### FastQ - Qualities

```
@HS2000-887_89:5:1101:1595:156011/1
2    ACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAACCCTAAC
```

- Qualities follow "+" line.
- -log10 probability of sequence base being wrong.
- Encoded in ASCI to save space.
- Used in quality assessment and downstream analysis

#### SAM format

- SAM Sequence Alignment Map.
- Standard format for sequence data
- Recognised by majority of software and browsers.

#### SAM - Header

```
@HD VN:1.4 SO:coordinate
   @SQ SN:chr10
                   LN:130694993
   @SO SN:chr11
                   LN:122082543
   @SQ SN:chr12
                   LN: 120129022
   @SQ SN:chr13
                   LN:120421639
   @SQ SN:chr14
                   LN:124902244
   @SQ SN:chr15
                 LN:104043685
   @SQ SN:chr16
                 LN:98207768
   @SQ SN:chr17
                   LN:94987271
   @SQ SN:chr18
                   LN:90702639
11 @SQ SN:chr19
                   LN:61431566
12 @SQ SN:chr1 LN:195471971
13 @SQ SN:chr2 LN:182113224
14 @SQ SN:chr3 LN:160039680
15 @SQ SN:chr4 LN:156508116
  @SQ SN:chr5 LN:151834684
17 @SQ SN:chr6 LN:149736546
18 @SO SN:chr7 LN:145441459
19 @SQ SN:chr8 LN:129401213
20 @SQ SN:chr9 LN:124595110
21 @SQ SN:chrM LN:16299
   @SQ SN:chrX LN:171031299
   @SQ SN:chrY LN:91744698
```

- SAM header contains information on alignment and contigs used.
- @HD Version number and sorting information
- @SQ Contig/Chromosome name and length of sequence.

#### SAM - Aligned Reads

```
13894
      HS2000-905_68:3:1307:14091:6825 137 chr2
                                       92045101
                                                 254 28M1D72M
      ATAGACAACTAACAGAGTGGGAACCCTGCCCCTGAACCCTGACCCCTAACCCCTGACCCTGACCACTAACCCCTGGCCATAACCCCTAACCCCTA
      BC:Z:0 XD:Z:11T16^A$5A1C45A18 SM:i:328
13895
     HS2000-905 68:1:1305:12812:167908 147 chr2
                                          92045105
                                                    254 100M
                                                                92044908
      TCAAAGAGTGGGACCCCTGACCCTGACCCTGACCCTGACCCTGACCCTGACCCCTGACCCCTAACCCCTAACCCCTAACCCCTAACCC
      CDDDCCDDDBDBBDDDDCCCCDDDCCDDDDB?DEEEEC@FFFFHGHGIGDC=IIIJIHGJJJHEDJJJIGF?IJJIIIHJJIGFCJJHHHFHFFFDD=@B
      AM:i:0 BC:Z:0 XD:Z:A3CT1TCA1AGTGGGAACC1TGAC4A14C8C12A13A18
13896
     HS2000-905 68:2:2107:9712:70649 163 chr2
                                       92045106
                                                 254 100M
                                                             92045307
                                                                      301
      CAACTATCAGAGGGGGAACCCTGACCCCTAACCCCTGACCCCTAACCCCTGACCCTGACCCTAACCCCTGACCCTGACCCTAACCCCTAACCCC
      BC:Z:0 XD:Z:12T51C27C1T5 SM:i:346
                                    AS:i:797
```

Contains read and alignment information and location

#### SAM

```
13894
    HS2000-905_68:3:1307:14091:6825_137_chr2
                                        254 28M1D72M
                                92045101
    ATAGACAACTAACAGAGTGGGAACCCTGCCCCTGAACCCTGACCCCTAACCCCTGACCCCTGACCACTAACCCCTGGCCATAACCCCTAACCCCTA
    BC:Z:0 XD:Z:11T16^A$5A1C45A18 SM:i:328
                                AS:i:0
    13895
                                   92045105
                                          254 100M
                                                    92044908
    CDDDCCDDDBDBBDDDDCCCCDDDCCDDDDB?DEEEEC@FFFFHGHGIGDC=IIIJIHGJJJHEDJJJIGF?IJJIIIHJJIGFCJJHHHFHFFFDD=@B
    AM:i:0 BC:Z:0 XD:Z:A3CT1TCA1AGTGGGAACC1TGAC4A14C8C12A13A18
    HS2000-905_68:2:2107:9712:70649 163 chr2
13896
                                92045106
                                        254 100M
                                                  92045307
                                                          301
     CAACTATCAGAGGGGGAACCCTGACCCCTAACCCCTGACCCCTAACCCCTGACCCTGACCACTAACCCCTGACCATAACCCCTAACCCC
     BC:Z:0 XD:Z:12T51C27C1T5 SM:i:346
                              AS: i:797
```

- Read name.
- Sequence of read.
- Encoded sequence quality.

#### SAM

```
13894
      HS2000-905_68:3:1307:14091:6825_137_chr2
                                                  254 28M1D72M
                                        92045101
      ATAGACAACTAACAGAGTGGGAACCCTGCCCCTGAACCCTGACCCCTAACCCCTGACCCCTGACCACTAACCCCTGGCCATAACCCCTAACCCCTA
      BC:Z:0 XD:Z:11T16^A$5A1C45A18 SM:i:328
                                        AS: i:0
      HS2000-905_68:1:1305:12812:167908 147 chr2
13895
                                           92045105
                                                     254 100M
      TCAAAGAGTGGGACCCCTGACCCTGACCCCTGACCCCTGACCCTGACCCTGACCCCTGACCCCTAACCCCTAACCCCTAACCCCTAACCCCTAACCCCTAACCCCTAACCC
      CDDDCCDDDBDBBDDDDCCCCDDDCCDDDDB?DEEEEC@FFFFHGHGIGDC=IIIJIHGJJJHEDJJJIGF?IJJIIIHJJIGFCJJHHHFHFFFDD=@B
      AM:i:0 BC:Z:0 XD:Z:A3CT1TCA1AGTGGGAACC1TGAC4A14C8C12A13A18
      HS2000-905_68:2:2107:9712:70649 163 chr2
13896
                                        92045106
                                                  254 100M
                                                                        301
      CAACTATCAGAGGGGGAACCCTGACCCCTAACCCCTGACCCCTAACCCCTGACCCTGACCACTAACCCCTGACCATAACCCCTAACCCC
      BC:Z:0 XD:Z:12T51C27C1T5 SM:i:346
                                     AS: i:797
```

- Chromosome to which read aligns.
- Position in chromosome to which 5' of read aligns.
- Alignment information "Cigar string".
  - 100M Continuous match of 100 bases
  - 28M1D72M 28 bases continuously match, 1 deletion from reference, 72 base match

#### SAM

```
13894
      HS2000-905_68:3:1307:14091:6825_137_chr2
                                                 254 28M1D72M
                                        92045101
      ATAGACAACTAACAGAGTGGGAACCCTGCCCCTGAACCCTGACCCCTAACCCCTGACCCCTGACCACTAACCCCTGGCCATAACCCCTAACCCCTA
      BC:Z:0 XD:Z:11T16^A$5A1C45A18 SM:i:328
                                        AS:i:0
13895
      HS2000-905_68:1:1305:12812:167908 147 chr2
                                           92045105
                                                     254 100M
      TCAAAGAGTGGGACCCCTGACCCTGACCCCTGACCCCTGACCCTGACCCTGACCCCTGACCCCTAACCCCTAACCCCTAACCCCTAACCCCTAACCCCTAACCCCTAACCC
      CDDDCCDDDBDBBDDDDCCCCDDDCCDDDDB?DEEEEC@FFFFHGHGIGDC=IIIJIHGJJJHEDJJJIGF?IJJIIIHJJIGFCJJHHHFHFFFDD=@B
     AM:i:0 BC:Z:0 XD:Z:A3CT1TCA1AGTGGGAACC1TGAC4A14C8C12A13A18
13896
      HS2000-905_68:2:2107:9712:70649 163 chr2
                                        92045106
                                                  254 100M
                                                                        301
      CAACTATCAGAGGGGGAACCCTGACCCCTAACCCCTGACCCCTAACCCCTGACCCTGACCCTAACCCCTGACCCTAACCCCTAACCCC
      BC:Z:0 XD:Z:12T51C27C1T5 SM:i:346
                                     AS: i:797
```

- Bit flag TRUE/FALSE for pre-defined read criteria
  - Paired? Duplicate?
  - https://broadinstitute.github.io/picard/explain-flags.html
- Paired read position and insert size
- User defined flags.

## Summarised Genomic Features formats

Post alignment, sequences reads are typically summarised into scores over/within genomic intervals.

- BED Genomic intervals and information.
- Wiggle/BedGraph Genomic intervals and scores.
- GFF Genomic annotation with information and scores

## Summarising in genomic intervals.

#### BED format (BED)

```
chr7
          127471196
                     127472363
  chr7
          127472363 127473530
  chr7
          127473530 127474697
  chr7
          127474697 127475864
  chr7
          127475864 127477031
6 chr7
          127477031 127478198
          127478198 127479365
  chr7
          127479365 127480532
8 chr7
9 chr7
          127480532 127481699
```

- Simple format
- 3 tab separated columns
- Chromsome, start, end

## Summarising in genomic intervals.

#### BED format (BED6)

```
chr7
           127471196
                     127472363
                               Pos1 10 +
                               Pos2 11 +
 2 chr7
           127472363
                     127473530
  3 chr7
           127473530
                     127474697
                               Pos3 20 +
 4 chr7
           127474697
                     127475864 Pos4 10 +
 5 chr7
           127475864 127477031 Neg1 98 -
           127477031
                     127478198 Neg2
                                    10 -
 6 chr7
 7 chr7
          127478198 127479365 Neg3 67 -
   chr7
           127479365
                     127480532 Pos5 20 +
           127480532 127481699 Neg4 50 -
   chr7
10
```

- Chromosome, start, end
- Identifier
- Score
- Strand (":" for strandless)

## Summarising in genomic intervals.

#### narrowPeak and broadPeak

- narrowPeak and broadPeak are extensions to BED6 used in Encode's peak calling.
- Contains p-values, q-values.
- narrowPeak BED 6+4
- broadPeak BED6+3

## Signal at genomic positions

- Common practice to review signal over genome.
- Special formats exist for this
  - Wiggle
  - bedGraph

# Signal at genomic positions Wiggle

```
variableStep chrom=chr21 span=5
    9411191 50
    9411196 40
    9411201 60
    9411206 20
    9411211 20
    9411216 20
    9411221 40
    9411226 60
    9411231 40
10
11
    9411236 40
12
    9411241 40
    9411246 40
    9411251 40
14
    9411256 60
15
16
    9411261 20
    9411266 60
17
18
    9411271 60
    9411276 40
19
20
    9411281 20
    9411286 40
22
    9411291 60
23
    9411296 60
24
    9411301 60
     9411306 20
```

- Information line
  - Chromosome
  - Step size
- Step start position
- Score

# Signal at genomic positions bedGraph

```
chr1
         10001
                  10002
                            1
chr1
                            10
         10003
                  10010
                            11
chr1
         10011
                  10020
chr1
         10021
                  10040
                            10
                            2
chr1
         10041
                  10050
chr1
                  99999
         10051
```

- BED 3 format
  - Chromosome
  - Start
  - End
- 4th column Score

```
##gff-version 3
chr1
       BLAST
                     1300
                           1500
                                    + ID=exon00001; PARENT=Gene1
              exon
                           1500 .
chr1 BLAST
              exon
                    1050
                                    + . ID=exon00002; PARENT=Gene1
                           3902 . + . ID=exon00003; PARENT=Gene1
5500 . + . ID=exon00004; PARENT=Gene1
chr1 BLAST
                    3000
              exon
chr1 BLAST
                    5000
              exon
chr1 BLAST
                    7000
                           9000
                                   + ID=exon00005;PARENT=Gene1
              exon
```

- Used to genome annotation.
- Stores position, feature (exon) and metafeature (transcript/gene) information.

```
##gff-version 3
chr1
      BLAST
                   1300
                         1500
                                        ID=exon00001; PARENT=Gene1
             exon
                         1500
chr1
      BLAST
                   1050
                                        ID=exon00002; PARENT=Gene1
             exon
                         3902
                                  + . ID=exon00003; PARENT=Gene1
chr1 BLAST
                   3000
             exon
chr1 BLAST
                   5000
                         5500
                                        ID=exon00004; PARENT=Gene1
             exon
chr1
      BLAST
                   7000
                         9000
                                        ID=exon00005; PARENT=Gene1
             exon
```

- Chromosome
- Start of feature
- End of Feature
- Strand

```
##gff-version 3
chr1
      BLAST
                  1300
                        1500
                                       ID=exon00001; PARENT=Gene1
             exon
chr1 BLAST
                  1050
                        1500
                              + . ID=exon00002;PARENT=Gene1
             exon
     BLAST
                        3902 . + . ID=exon00003; PARENT=Gene1
chr1
             exon
                  3000
      BLAST
                        5500
                              + . ID=exon00004;PARENT=Gene1
chr1
                  5000
             exon
chr1
      BLAST
                   7000
                        9000
                                       ID=exon00005; PARENT=Gene1
             exon
```

- Source
- Feature type
- Score

```
##gff-version 3
                             + ID=exon00001; PARENT=Gene1
chr1 BLAST
                       1500
            exon
                  1300
chr1 BLAST
                       1500 . + . ID=exon00002; PARENT=Gene1
                 1050
            exon
                       3902 . + . ID=exon00003; PARENT=Gene1
chr1 BLAST exon 3000
chr1 BLAST exon 5000
                       5500 . + . ID=exon00004; PARENT=Gene1
chr1 BLAST
                 7000
                       9000
                                    ID=exon00005; PARENT=Gene1
            exon
```

- Column 9 contains key pairs (ID=exon01), separated by semi-colons ";"
- ID Feature name.
- PARENT- Meta-feature name.

# Saving time and space big Wig, bigBED and TABIX

- Many programs and browsers deal better with compressed, indexed versions of genomic files
  - SAM -> BAM (.bam and index file of .bai)
  - Wiggle and bedGraph -> bigWig (.bw/.bigWig)
  - BED -> bigBed (.bb)
  - BED and GFF -> (.gz and index file of .tbi)

## Getting help and more information

- UCSC file formats
  - https://genome.ucsc.edu/FAQ/FAQformat.html
- IGV file formats
  - https://www.broadinstitute.org/igv/FileFormats
- Sanger (GFF)
  - https://www.sanger.ac.uk/resources/software/gff/spec.html